

Caracal-1 · plano MVP

Plano enxuto. Começar simples, treinar primeiro, melhorar depois. Sem cloud pago no começo. So Kaggle + HuggingFace + Weights and Biases (tudo gratis). Atualizado 23 jun 2026.

Filosofia: primeira versao do Caracal Base 3B funcionando em 2 semanas com recursos gratis. Avaliar. So depois adicionar Modal sandbox, Colab Pro+, multi-modulo, recursive harness e os outros enfeites.

1. O que vamos treinar primeiro

Caracal Base 3B v0. Qwen2.5-Coder-3B-Instruct mais continued pretrain enxuto com 3 datasets ja disponiveis no HuggingFace. Sem scraping, sem coleta de NVD/GitHub patches/Project Zero/Trail of Bits. So pegar e treinar.

O QUE	DETALHE
Base	Qwen2.5-Coder-3B-Instruct (Apache 2.0)
Tokens treino v0	~500 milhoes (3 datasets HF, sem scraping)
Framework	Unsloth + TRL SFTTrainer (1 placa T4)
Tempo treino	~25 horas T4 (cabe em 3 sessoes Kaggle)
Output	<code>iterate-labs/caracal-base-3b-v0</code> no HF Hub
Alvo v0	Roda. Salva. Carrega. Roda inferencia simples.

2. Datasets minimos (3 ja prontos no HF, 0 de scraping)

DATASET	TAMANHO	HF
---------	---------	----

PrimeVul	~150M tokens	secmlr/PrimeVul
BigVul	~200M tokens	bstee615/bigvul
DiverseVul	~150M tokens	bstee615/diversevul

Total ~500M tokens. Tudo Apache/MIT/CC-BY. Carrega via `datasets.load_dataset()` . Zero coleta manual. Decontamination simples (CVE-ID dedup contra CyberGym antes de treinar).

Cortado do plano: Project Zero + Trail of Bits + AFL++ docs + NIST Juliet/SARD + Devign + VulDeePecker + CrossVul + MegaVul + Reposvul + PatchDB + SVEN + execution traces. Tudo isso fica pra v1 ou v2 depois que MVP funcionar.

3. Stack tecnico minimo (tudo gratis)

CAMADA	ESCOLHA	CUSTO
Placa de video	Kaggle T4 · 5 contas × 20h/sem = 100h/sem	\$0
Framework treino	Unsloth + TRL SFTTrainer	\$0
Modelo base	Qwen2.5-Coder-3B-Instruct	\$0
Storage de pesos	HuggingFace Hub (gratis ate 100GB)	\$0
Tracking	Weights and Biases gratis academic	\$0
Datasets	HuggingFace Datasets (PrimeVul, BigVul, DiverseVul)	\$0
Codigo	GitHub iterate-labs-ai (ja temos)	\$0

Total mensal MVP: \$0. Nada de Modal, Colab Pro+, Wasabi, ou cloud paga.

O que NAO usar agora

RECURSO	POR QUE CORTEI	QUANDO VOLTAR
Modal CPU sandbox	\$300/mes · so precisa quando rodar RL com PoC executando · MVP nao chega la	Sprint 3 quando comecar RL
Colab Pro+ 20 contas	\$1000/mes · Kaggle T4 gratis suficiente pra v0 SFT	Avaliar apos v0 medir tempo de treino real
Wasabi/Backblaze storage	\$50/mes · HF Hub gratis aguenta	Se passar 100GB no HF
NVD scraping	2 semanas de dev pra coletar · dataset HF cobre	v1 se precisar mais tokens
Project Zero/ToB scraping	Idem	v1
5 modulos LoRA especialistas	Complexidade alta · MVP precisa 1 modelo funcionando primeiro	Sprint 2 apos Base funcionar
Embodied gdb live (Recon)	2 semanas de dev pra sandbox + protocol	v2 ou v3
SMT Z3 (Validator)	Idem	v2
Mental simulator head	Precisa traces de execucao = coleta complexa	v2
SAE features	Pesquisa nivel Anthropic	v3
Caracal-XS WebGPU edge	Polish final	Pos ship
Recursive harness 6 loops	Trabalho de meses	v2 ou v3

4. Caminho critico · 10 tarefas

Da pra terminar em 2 semanas com 5 pessoas no pool aberto.

T1 5 contas Kaggle phone-verified + GPU ativada

CRITICA

Cada fundador 1 conta Kaggle, phone verify, ativar T4. Dia 1.

T2 Conta org HuggingFace + W&B + secrets

CRITICA

Aceitar convite org iterate-labs no HF e W&B. Gerar HF token write. Configurar como Kaggle Secrets (HF_TOKEN, WANDB_API_KEY).

T3 Baixar e olhar os 3 datasets HF

MUST

Rodar `load_dataset` nos 3, ver schema, contar tokens reais, escolher campo de texto. ~2h dev.

T4 Script unico de continued pretrain Unsloth + TRL

MUST

Implementacao funcional em `train/continued_pretrain.py`. Carrega Qwen-Coder-3B, mistura 3 datasets, treina SFT com LoRA r=32, push HF Hub a cada 200 passos. Ja existe stub no repo, precisa testar smoke run de 100 passos.

T5 Decontamination CVE-ID dedup vs CyberGym

MUST

So a camada de CVE-ID (rapido). Tira de PrimeVul/BigVul/DiverseVul qualquer CVE que aparece em CyberGym 1507. Ja existe stub funcional em `eval/check_decontamination.py`, precisa rodar e ver resultado.

T6 Schedule de revezamento 3 sessoes Kaggle

MUST

Atualizar SCHEDULE.md com 3 slots de 9h cobrindo 25h total. 3 fundadores tomam 1 cada. Resto do time observa.

T7 Sessao 1 · primeiros 9h treino (smoke)

CRITICA

Primeiro fundador roda notebook Kaggle. Confirma que treino comeca, loss desce, push HF Hub funciona. Salvar revision `step-1`.

T8 Sessao 2 · continua 9h

MUST

Segundo fundador resume from `step-1`. Push `step-2`.

T9 Sessao 3 · finalizar Caracal Base 3B v0

MUST

Terceiro fundador. Push final `caracal-base-3b-v0` como repository tag estavel.

T10 Avaliacao basica · 50 vulns CyberGym

MUST

Carregar Caracal Base 3B v0 + Qwen Coder 3B base zero-shot. Comparar pass@1 em 50 vulneraveis CyberGym subset. Pareto: ganho ou perda?

5. Setup de cada fundador (gratis, 15 minutos)

Passo 1 · Aceitar convite GitHub

github.com/orgs/iterate-labs-ai/invitations

Passo 2 · Conta HuggingFace + token write

huggingface.co/join · gerar token em [/settings/tokens](#) · mandar handle pro Pedro pra ele incluir na org [iterate-labs](#)

Passo 3 · Conta Weights and Biases

wandb.ai/signup · pegar key em [/authorize](#) · mandar handle pro Pedro

Passo 4 · Conta Kaggle phone-verified

kaggle.com/account/login · phone verify · ativar GPU T4 em [/settings](#) · baixar `kaggle.json`

Passo 5 · Configurar Kaggle Secrets

No proprio Kaggle: Add-ons > Secrets > criar `HF_TOKEN` e `WANDB_API_KEY`

So isso. **15 minutos**. Sem Colab Pro+, sem Modal, sem cartao de credito.

6. Schedule simplificado · 3 sessoes (~25h)

SESSAO	QUANDO	QUEM	STEPS	OUTPUT REVISION
1	seg 24 jun 14h-23h BRT	fundador X	0 → 7000	step-7000
2	ter 25 jun 09h-18h BRT	fundador Y	7000 → 14000	step-14000
3	ter 25 jun 19h-04h	fundador Z	14000 → 20000	caracal-base-3b-v0 (final)

Sao 3 fundadores, cada um faz uma sessao de 9h. Os outros 2 observam, debugam se quebra, ajudam revisao. Apos terminar, todo time olha resultado v0 + decide proximos passos.

7. Como treinar (concreto)

7.1 No Kaggle, criar notebook novo, copiar codigo abaixo

```
!git clone https://github.com/iterate-labs-ai/caracal-1.git
%cd caracal-1
!git checkout dev
!pip install --quiet 'unsloth[kaggle-new] @ git+https://github.com/unslothai/unsloth.git'
!pip install --quiet trl peft datasets huggingface_hub wandb pyyaml

from kaggle_secrets import UserSecretsClient
import os
secrets = UserSecretsClient()
os.environ['HF_TOKEN'] = secrets.get_secret('HF_TOKEN')
os.environ['WANDB_API_KEY'] = secrets.get_secret('WANDB_API_KEY')
!huggingface-cli login --token $HF_TOKEN --add-to-git-credential
!wandb login $WANDB_API_KEY

# Variaveis do seu slot:
SESSION = 1
RESUME = None # None se for sessao 1; senao 'step-7000' etc
OUTPUT = 'step-7000'
```

STEPS = 7000

```
import subprocess, sys
resume_arg = ['--resume-from', f'huggingface://iterate-labs/caracal-base-3b-v0@{RESUME}']
subprocess.run([sys.executable, 'train/continued_pretrain.py',
                '--config', 'train/configs/caracal_base_3b.yaml',
                *resume_arg,
                '--steps-to-run', str(STEPS),
                '--output', './ckpt-out',
                '--hf-revision-out', OUTPUT], check=True)
```

7.2 Apos sessao terminar (manualmente)

1. Verificar revision pushed em huggingface.co/iterate-labs/caracal-base-3b-v0
2. PR pequena editando `SCHEDULE.md` : trocar slot N de `pending` para `done` · `revision step-XXXX`
3. Sinalizar Discord/grupo: "sessao N completa, revision XXXX disponivel"
4. Proximo do relay configura RESUME = ultima revision e roda

8. Apos v0 · decidir baseado em medicaao

Quando Caracal Base 3B v0 estiver no HF Hub e avaliacao basica em 50 vulns rodada, time se reúne e decide:

RESULTADO V0	PROXIMO PASSO
Score sobe vs Qwen base (mesmo <5 pontos)	Continuar caminho · adicionar mais datasets (v1 com Project Zero + scraping NVD)
Score nao move	Repensar: talvez precisa mais tokens, ou mais epocas, ou dataset com PoCs estruturados
Score cai	Hyperparam errado ou contaminacao mascarando avaliacao · debug
Treino quebra antes de v0 ficar pronto	Bug no script · debug + retry

So apos v0 funcionar e a gente decide se adiciona:

- Mais datasets (scraping NVD, Project Zero, etc)
- 5 modulos LoRA especialistas
- Modal sandbox para RL com PoC executando
- Colab Pro+ para acelerar (se Kaggle T4 demorando demais)
- Avaliacao completa CyberGym 1507
- Caça zero-day em held-out 30 CVE 2026
- Paper preprint arXiv

9. Mensagem pronta pra enviar aos fundadores

Galera, começamos Caracal-1 nessa segunda. Plano minimo, gratis.

Repo: github.com/iterate-labs-ai/caracal-1 (branch dev)

Setup 15 minutos (so contas gratis):

1. Aceitar convite GitHub [iterate-labs-ai](#)
2. Criar conta HuggingFace + token write + me mandar handle
3. Criar conta Weights and Biases + me mandar handle
4. Conta Kaggle phone-verified + ativar GPU T4 + Kaggle Secrets (HF_TOKEN, WANDB_API_KEY)

Pronto. SEM Colab Pro+, SEM Modal, SEM nada pago.

Primeira meta: treinar Caracal Base 3B v0 (Qwen Coder 3B mais 3 datasets HF de vuln). 25 horas T4 total em 3 sessoes de 9 horas.

Datasets usados:

- [secmlr/PrimeVul](#)
- [bstee615/bigvul](#)
- [bstee615/diversevul](#)

Quem topa pegar sessao 1 (seg 24 jun 14h-23h)? Outras duas (ter 25 jun 09h e 19h) precisam de quem tambem.

Plano completo em [docs/plan/iterate_labs.html](#) no repo.

Bora.

10. Glossario rapido

TERMO	SIGNIFICADO
LoRA r=32	Adapter de baixo posto. Treina ~1% dos parametros. Salva 130MB em vez de 6GB.
SFT	Supervised Fine-Tuning. Treino com pares (input, output esperado).
Continued pretrain	Continua o treino com corpus novo antes do SFT.
HF Hub	HuggingFace Hub. Onde a gente publica modelos.
Revision	Snapshot imutavel de um modelo no HF Hub (tipo commit no git).
Kaggle T4	Placa de video gratis no Kaggle (16GB). Aguenta modelo 3B sem quantizar.
Unsloth	Framework de treino otimizado. 2-5x mais rapido que TRL puro. 80% menos memoria.
CyberGym	Benchmark Berkeley com 1507 vulnerabilidades reais. Avaliacao.
CVE	Catalogo publico de vulnerabilidades.

Plano MVP. Sem fluff. Bora rodar primeiro, melhorar depois.

Repo: github.com/iterate-labs-ai/caracal-1